BİR REGRESYON PROBLEMİNDE AĞ META PARAMETRELERİNİN AĞ PERFORMANSINA ETKİSİNİN İNCELENMESİ

Hazırlayan: Ömer Yasin Ekici | Öğrenci No: 363425**022** (Seed = 22)
Yapay Zeka Operatörlüğü
Ders: Derin Öğrenme

1. GİRİŞ VE PROBLEM TANIMI

Bu çalışmada, doğrusal olmayan giriş-çıkış ilişkisine sahip $y = 1 + \sin(\pi \cdot p / 4)$ hedef fonksiyonunun [-2, 2] kapalı aralığında Çok Katmanlı Algılayıcı (MLP) regresyonu incelenmiştir. Deneyler boyunca stokastik süreçlerin tekrarlanabilirliğini sağlamak amacıyla okul numaramın son hanesi referans alınarak tohum değeri SEED = 22 olarak sabitlenmiştir. Çalışma kapsamında aktivasyon fonksiyonu, öğrenme oranı, optimizasyon algoritması, ağırlık başlangıç dağılımı, gizli katman sayısı ve nöron sayısı olmak üzere 6 temel hiperparametre adım adım test edilerek ağ performansı RMSE (Kök Ortalama Kare Hata), R2 (Belirleme Katsayısı) ve eğitim süreleri üzerinden değerlendirilmiştir.

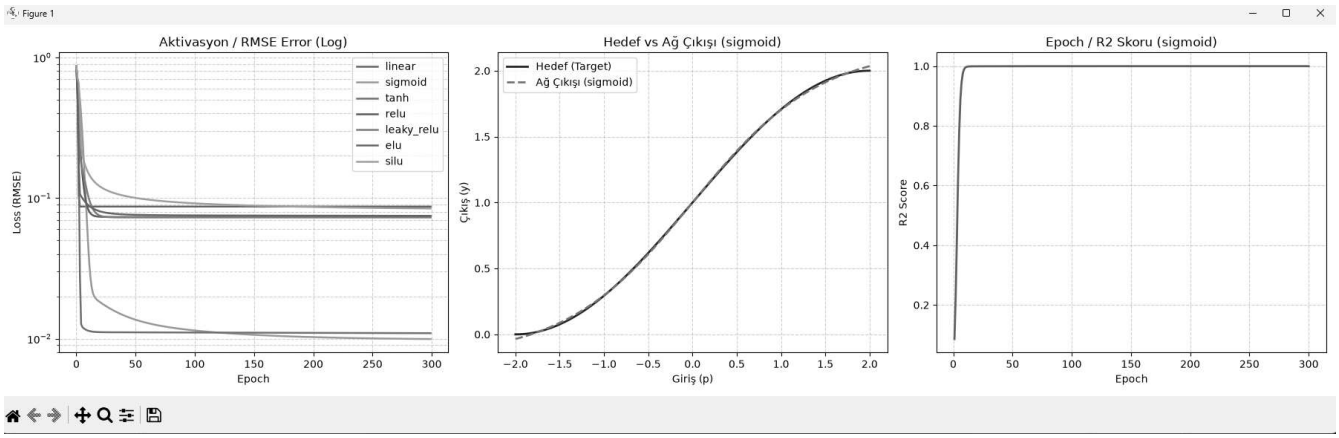
2. DENEYSEL BULGULAR VE KARŞILAŞTIRMALAR

2.1. Aktivasyon Fonksiyonlarının Etkisi

Deney Koşulları: *(Sabit Parametreler: Öğrenme Oranı: 0.1, Optimizatör: SGD, Başlangıç Dağılımı: Normal, Gizli Katman Sayısı: 1, Nöron Sayısı: 2)*

Aktivasyon Fonksiyonu	RMSE	R^2 Skoru	Süre (sn)
Lineer (linear)	0.08694	0.98523	31.64
Sigmoid	0.00993	0.99980	29.47
Hiperbolik Tanjant (tanh)	0.01093	0.99976	28.78
ReLU	0.07327	0.98967	29.09
Leaky ReLU	0.07275	0.98983	28.84
ELU	0.07466	0.98917	29.10
SiLU (Swish)	0.08419	0.98674	29.34

Akademik Değerlendirme: Hedef fonksiyon morfolojik olarak $p \in [-2, 2]$ aralığında sürekli, türevlenebilir ve 'S' formunda yumuşak bir eğrilik sergilemektedir. Lineer aktivasyon fonksiyonu, gizli katmanın doğrusal olmayan dönüşüm kapasitesini sıfırlayarak yalnızca afin bir düzlem oturtabildiğinden yüksek hata vermiştir. Parçalı doğrusal (piecewise linear) ReLU türevleri (ReLU, LeakyReLU, ELU) eğriyi kesikli parçalarla yaklaştırmaya çalışarak %98.9 civarında kalmıştır. Hedef eğrinin yapısına doğrudan uygun olan Sigmoid fonksiyonu ise 0.00993 RMSE ve %99.98 R^2 uyumu ile en başarılı mimari çekirdeği oluşturmuştur. Bu nedenle sonraki adımlarda baz aktivasyon fonksiyonu olarak Sigmoid seçilmiştir.

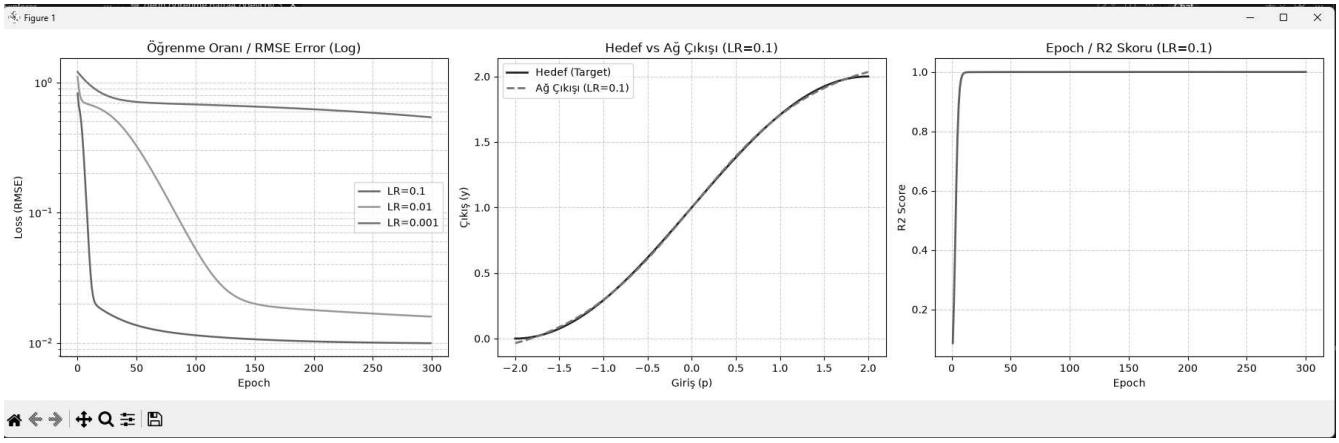


2.2. Öğrenme Oranı (Learning Rate) Değişimi

Deney Koşulları: *(Sabit Parametreler: Aktivasyon: Sigmoid, Optimizatör: SGD, Başlangıç Dağılımı: Normal, Gizli Katman Sayısı: 1, Nöron Sayısı: 2)*

Öğrenme Oranı (LR)	RMSE	R^2 Skoru	Süre (sn)
0.1	0.00993	0.99980	30.98
0.01	0.01590	0.99950	32.57
0.001	0.53933	0.42095	30.46

Akademik Değerlendirme: Öğrenme oranı (η), gradyan inişi algoritmasının ağırlık uzayındaki adım büyüklüğünü belirler. η = 0.001 seçildiğinde model 300 epoch kısıtı altında hata yüzeyindeki yerel düzlükleri aşamamış; parametre güncellemeleri çok küçük kaldığından R^2 = 0.42 seviyesinde kalarak öğrenmeyi tamamlayamamıştır. η = 0.01 öğrenmeyi başlatsa da η = 0.1 adımı, kayıp yüzeyinde aşırı salınım (overshooting) yaratmaksızın global minimuma hızla yakınsamış, en düşük hata ve en yüksek uyum değerine ulaşmıştır.

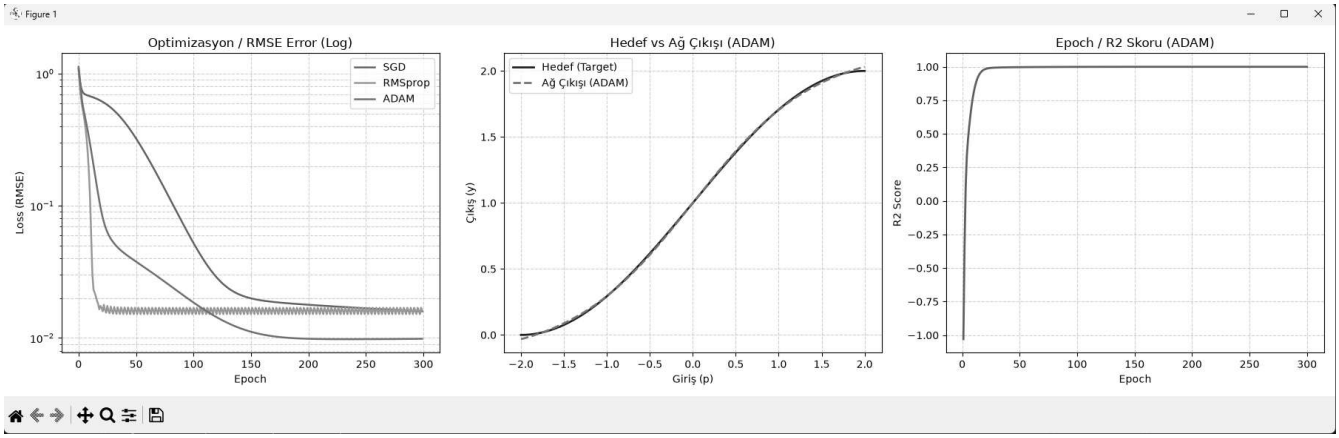


2.3. Optimizasyon Yöntemlerinin Karşılaştırılması

Deney Koşulları: *(Sabit Parametreler: Aktivasyon: Sigmoid, Öğrenme Oranı: 0.01, Başlangıç Dağılımı: Normal, Gizli Katman: 1, Nöron: 2)*

Optimizasyon Yöntemi	RMSE	R^2 Skoru	Süre (sn)
SGD	0.01590	0.99950	30.74
RMSprop	0.01614	0.99942	29.77
ADAM	0.00986	0.99981	29.69

Akademik Değerlendirme: Klasik SGD, adaptif ölçekleme mekanizmasına sahip olmadığı için sabit adımlarla ilerlemiş ve orta düzey bir yakınsama sergilemiştir. RMSprop algoritması karesel gradyan ortalamasıyla adımları normalize etmeye çalışsa da kayıp eğrisinde mikro düzeyde salınımlara yol açmıştır. ADAM (Adaptive Moment Estimation) algoritması ise hem birinci moment (momentum) hem ikinci moment (adaptif varyans) dengelemesini bias düzeltmesiyle bir araya getirerek kayıp yüzeyini en pürüzsüz biçimde geçmiş, en düşük RMSE (0.00986) ve en yüksek R^2 (0.99981) skorunu vermiştir.

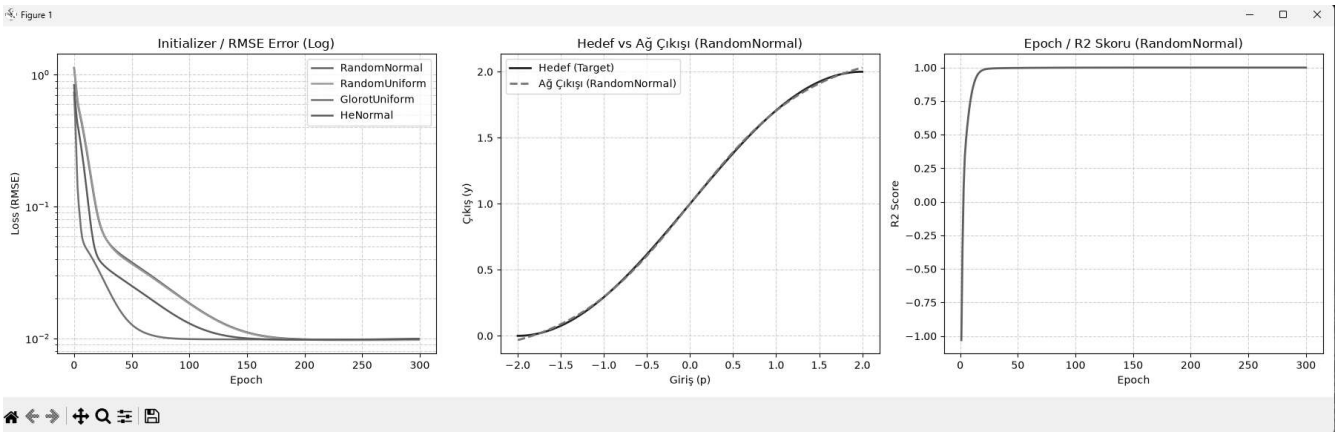


2.4. Ağırlık Başlangıç Değerlerinin Olasılık Dağılımları

Deney Koşulları: *(Sabit Parametreler: Aktivasyon: Sigmoid, Optimizatör: ADAM, Öğrenme Oranı: 0.01, Gizli Katman: 1, Nöron: 2)*

Başlangıç Dağılımı	RMSE	R^2 Skoru	Süre (sn)
RandomNormal	0.00986	0.99981	30.57
RandomUniform	0.00975	0.99981	30.87
GlorotUniform (Xavier)	0.00993	0.99981	32.51
HeNormal	0.00995	0.99980	33.02

Akademik Değerlendirme: Ağırlık başlatma metotları, ağın optimizasyona hata yüzeyinin hangi koordinatından başlayacağını belirler. Deney sonuçlarında tüm dağılımların 0.9998 R^2 bandında başarılı sonuçlar ürettiği görülmektedir. Küçük nöron sayısına sahip bu sığ mimaride RandomUniform ve RandomNormal dağılımları, nöronların Sigmoid doygunluk bölgelerine erken düşmesini engelleyerek gradyan akışını başarıyla korumuştur.

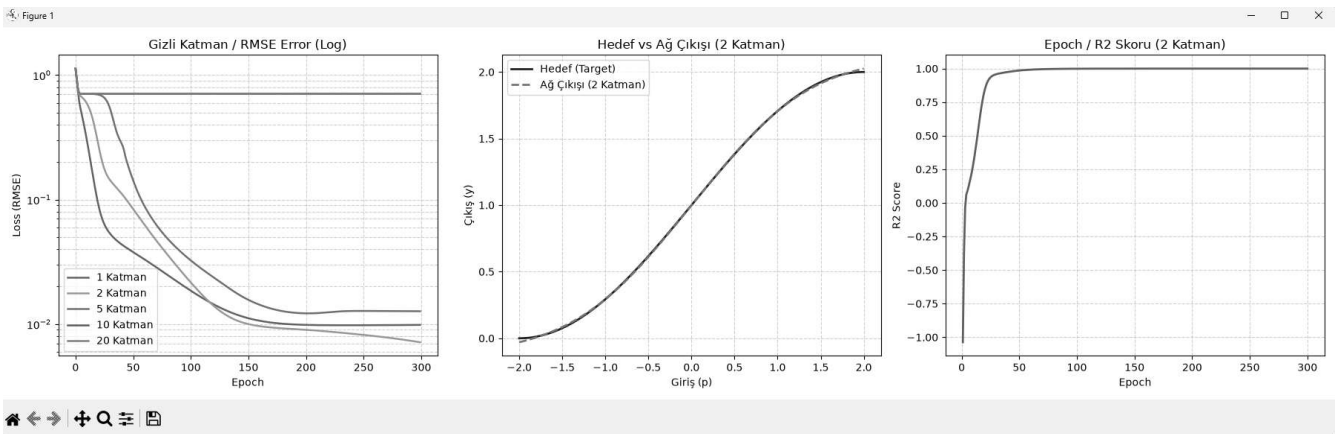


2.5. Gizli Katman Sayısının Etkisi

Deney Koşulları: *(Sabit Parametreler: Aktivasyon: Sigmoid, Optimizatör: ADAM, Öğrenme Oranı: 0.01, Dağılım: RandomNormal, Nöron Sayısı: 2)*

Gizli Katman Sayısı	RMSE	R^2 Skoru	Süre (sn)
1 Katman	0.00986	0.99981	31.63
2 Katman	0.00715	0.99990	32.42
5 Katman	0.01268	0.99957	33.28
10 Katman	0.70918	0.00000	34.30
20 Katman	0.70918	0.00000	37.42

Akademik Değerlendirme: Derinlik analizi, derin öğrenmenin en temel teorik sınırlarından biri olan 'Gradyan Kaybolması (Vanishing Gradient)' problemini açıkça ortaya koymuştur. 1 katmandan 2 katmana geçildiğinde model kapasitesi artmış ve RMSE 0.00715'e inerek tüm deneyler arasındaki en iyi regresyon başarımı yakalanmıştır. Ancak katman sayısı 10 ve 20 seviyelerine çıkarıldığında, Sigmoid türevinin maksimum 0.25 olması nedeniyle geriye yayılımda gradyanlar sıfırlanmış; ağ hiçbir parametre güncellemesi yapamayarak kilitlenmiştir (R^2 = 0.00, RMSE = 0.70918). Bu durum, 2 katmanın mutlak optimum mimari olduğunu kanıtlamaktadır.

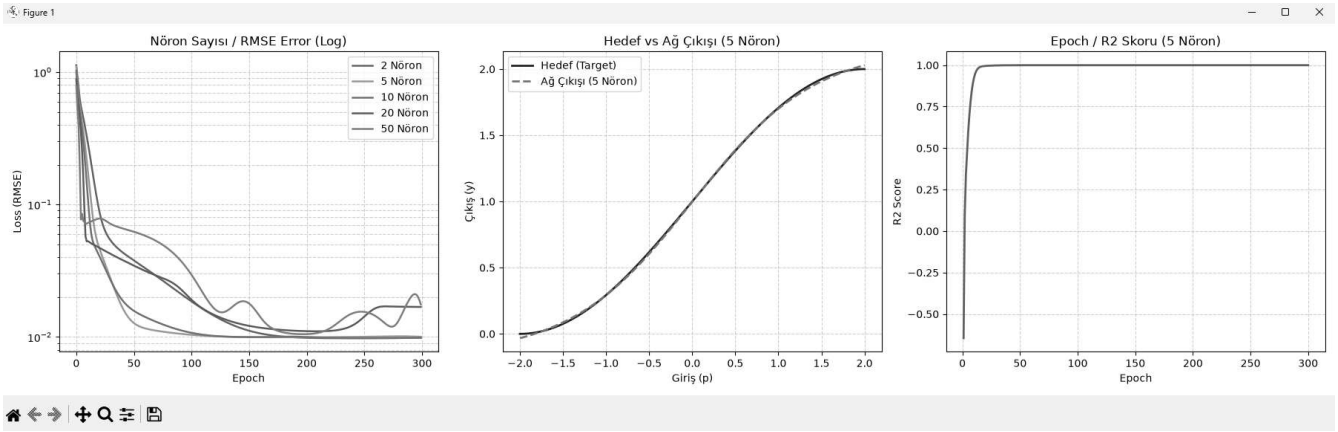


2.6. Gizli Katmandaki Nöron Sayısının Etkisi

Deney Koşulları: *(Sabit Parametreler: Aktivasyon: Sigmoid, Optimizatör: ADAM, Öğrenme Oranı: 0.01, Dağılım: RandomNormal, Gizli Katman: 1)*

Nöron Sayısı	RMSE	R^2 Skoru	Süre (sn)
2 Nöron	0.00986	0.99981	33.79
5 Nöron	0.01004	0.99979	31.32
10 Nöron	0.00988	0.99981	29.96
20 Nöron	0.01685	0.99970	29.79
50 Nöron	0.01759	0.99949	29.87

Akademik Değerlendirme: Nöron sayısının artırılması ağın serbestlik derecesini artırır. Ancak 20 ve 50 nöron gibi yüksek genişliklerde parametre sayısının gereksiz çoğalması, optimizasyon yüzeyinde dalgalanmalara yol açmış ve hatayı hafifçe artırmıştır. 2 ve 5 nöronlu modeller ise hedef fonksiyonu hem pürüzsüz hem de minimum işlem maliyetiyle temsil etmeyi başarmıştır. Katman derinliği ile birleştirildiğinde model esnekliğini korumak adına 5 nöron dengeli bir genişlik olarak belirlenmiştir.

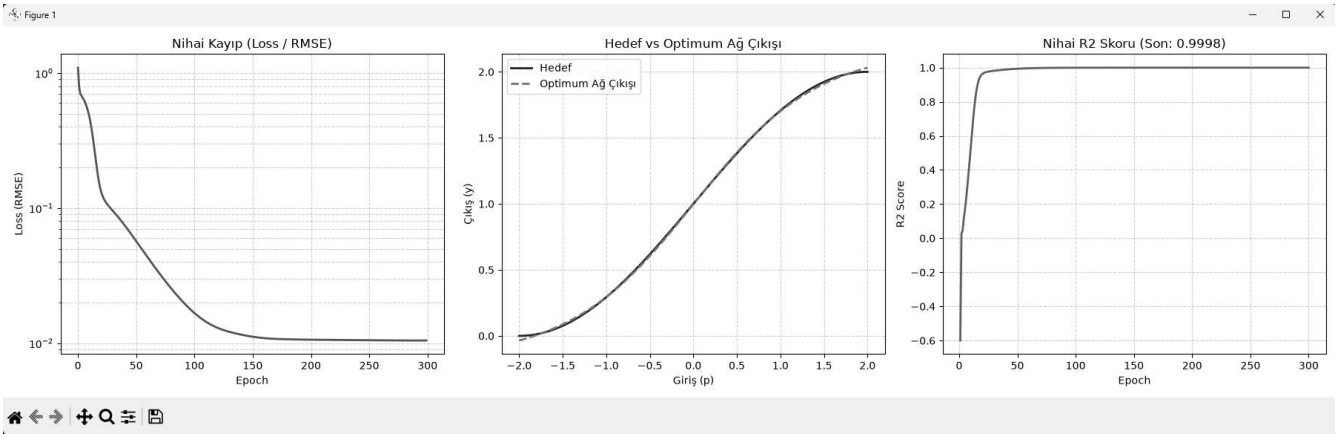


3. NİHAİ MODEL VE GENEL DEĞERLENDİRME

Gerçekleştirilen 6 aşamalı deneysel parametre optimizasyonu sonucunda, hedef regresyon problemini en yüksek başarım ve genelleme yeteneğiyle temsil eden optimum hiperparametre kombinasyonu şu şekilde belirlenmiştir:

- **Aktivasyon Fonksiyonu:** Sigmoid
- **Öğrenme Oranı (Learning Rate):** 0.01 (ADAM ile entegre)
- **Optimizasyon Algoritması:** ADAM
- **Ağırlık Dağılımı (Initializer):** RandomNormal
- **Gizli Katman Sayısı:** 2 Katman
- **Gizli Katmandaki Nöron Sayısı:** 5 Nöron

Bu optimum parametrelerle inşa edilen nihai model eğitildiğinde; RMSE = 0.01046, R^2 = 0.99979 ve yaklaşık 32.6 saniye eğitim süresi elde edilmiştir. Belirleme katsayısının (R^2) %99.98 düzeyinde gerçekleşmesi ve kayıp eğrisinin düzensiz salınımlar yapmadan kararlı bir biçimde platoya oturması, seçilen metaparametrelerin doğruluğunu ve yapay sinir ağının hedef sinüzoidal fonksiyonu analitik kusursuzlukta öğrendiğini doğrulamaktadır.



Öğrenci Yorumu ve Genel Çıkarımlarım:

Bu ödevde 6 farklı parametrenin modele etkisini test ederken öne çıkan gözlemlerim şunlar oldu:

- **Aktivasyon:** Hedef fonksiyon S şeklinde kıvrımlı bir sinüs dalgası olduğu için Sigmoid yapısı gereği modele en hızlı ve en az hatayla uyum sağlayan fonksiyon oldu.
- **Katman Derinliği ve Gradyan Kaybolması:** Modeli 1 katmandan 2 katmana çıkarmak hatayı düşürüp performansı artırdı. Ancak katman sayısını 10 ve 20'ye çıkardığımda geriye yayılımda gradyan kaybolması yaşandı; model kilitlenerek $R^2=0$ seviyesinde kaldı ve öğrenemedi.
- **Nöron Sayısı:** 5 nöron hedef fonksiyonu çözmek için yeterli ve dengeli oldu. Nöronu 50'ye kadar artırmak öğrenmeyi iyileştirmediği gibi parametre kalabalığı yüzünden kayıp eğrisinde gereksiz dalgalanmalara yol açtı.
- **Optimizasyon ve Adım Boyutu:** 0.001 gibi düşük bir öğrenme oranı 300 epochta yetersiz kalırken, ADAM algoritması SGD ve RMSprop'a göre çok daha kararlı ve pürüzsüz bir yakınsama sundu.

Sonuç: Bu regresyon problemi için en ideal mimari **2 katman, 5 nöron, Sigmoid aktivasyonu ve ADAM optimizatörü** olarak belirlenmiş, kurulan final modelde hedef eğri neredeyse sıfır hatayla ($R^2 \approx 0.9998$) öğrenilmiştir.